

INTRODUCTION AUX MODÈLES DE LANGUE

SÉANCE 1/3 : HISTORIQUE, CONSTRUCTION, LIMITES

AgroParisTech — Dominante GIPE

Cas d'usage : évaluation de la valeur des entreprises

Vincent Guigue

vincent.guigue@agroparistech.fr


<https://vguigue.github.io>

INTRODUCTION



Un rapide tour historique de l'Intelligence Artificielle


Naissance de l'informatique... Et de l'Intelligence Artificielle





Un rapide tour historique de l'Intelligence Artificielle


Emergence (ou refondation) des GAFAM/GAMMA





Un rapide tour historique de l'Intelligence Artificielle


Emergence (ou refondation) des GAFAM/GAMMA






Un rapide tour historique de l'Intelligence Artificielle

Formation d'une vague de l'Intelligence Artificielle





Artificial Intelligence & Machine Learning



Input ($\mathbf{x}$)	Output ($\mathbf{Y}$)	Application
email	→ spam? (0/1)	spam filtering
audio	→ text transcript	speech recognition
English	→ Chinese	machine translation
ad, user info	→ click? (0/1)	online advertising
image, radar info	→ position of other cars	self-driving car
image of phone	→ defect? (0/1)	visual inspection

IA : programmes informatiques qui s'adonnent à des tâches qui sont, pour l'instant, accomplies de façon plus satisfaisante par des êtres humains car elles demandent des processus mentaux de haut niveau.

Marvin Lee Minsky, 1956


N-AI (Narrow Artificial Intelligence), dédiée à une tâche unique

≠ IA-G (IA Générale), qui remplace l'humain dans les systèmes complexes.

Andrew Ng, 2015




Chaîne de Traitement Supervisé & Modèles



- Promesse = construire un modèle *uniquement* à partir d'observations




Chaîne de Traitement Supervisé & Modèles






Chaîne de Traitement Supervisé & Modèles





Chaîne de Traitement Supervisé & Modèles




■ Initialisation aléatoire...

Et prise de décision aléatoire (au début !)



Chaîne de Traitement Supervisé & Modèles





- Mise à jour des poids
- Pas de taille epsilon, nombreuses itérations sur les données



Mesurer les performances des modèles

Estimer la performance en généralisation...





Est aussi important que de construire le modèle



Crédit: https://github.com/phalanx-hk/eccv2020_paperlist/issues/5

$$\text{Précision} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux positifs}}$$

$$\text{Rappel} = \frac{\text{vrais positifs}}{\text{vrais positifs} + \text{faux négatifs}}$$






Mesurer les performances des modèles

Estimer la performance en généralisation...

Est aussi important que de construire le modèle






Mesurer les performances des modèles

Estimer la performance en généralisation...


Est aussi important que de construire le modèle






Apprentissage/Construction vs Déploiement/Exploitation

Différentes étapes en apprentissage automatique





Les ingrédients du machine learning



DEEP LEARNING & APPRENTISSAGE DE REPRÉSENTATIONS

[APPLICATION AUX DONNÉES TEXTUELLES]




Des données tabulaires au texte

■ Données tabulaires

- Dimension fixe
- Valeurs continues

⇒ Un terrain de jeu idéal pour l'apprentissage automatique



■ Données textuelles

- Longueurs variables
- Valeurs discrètes

⇒ Complexes pour l'apprentissage automatique

This new iPhone, what a marvel

An iPhone, What a scam!

Half the price is for the logo

Apple once again proves that perfection can be sold

How do we turn this text data into a table?






IA + Texte : Trait. Auto. du Langage Naturel (TALN)

TALN = plus grande communauté scientifique en IA

Linguistique [1960-2010]

Systèmes à base de règles :




- Nécessite une expertise humaine
- Extraction de règles $\Leftrightarrow$ données très propres
- Très grande précision
- Faible rappel
- Système interprétable



IA + Texte : Trait. Auto. du Langage Naturel (TALN)

TALN = plus grande communauté scientifique en IA

Apprentissage auto. [1990-2015]





IA + Texte : Trait. Auto. du Langage Naturel (TALN)

TALN = plus grande communauté scientifique en IA

Linguistique [1960-2010]

- Nécessite une expertise humaine
- Extraction de règles $\Leftrightarrow$
données très propres
- + Système interprétable
- + Très grande précision
- Faible rappel

Apprentissage auto. [1990-2015]

- Peu d'expertise nécessaire
- Extraction statistique $\Leftrightarrow$
robuste aux données bruitées
- $\approx$ Système moins interprétable
- Moindre précision
- + Meilleur rappel

Précision = critère d'acceptation par l'industrie

→ Lien vers les métriques



Apprentissage de représentations pour les données textuelles

Du sac de mots aux représentations vectorielles


[2008, 2013, 2016]

Corpus en sac de mots


d1	1	0	0
d2	0	0	1
d3	0	1	0

mot 1 ... voiture ... automobile chat ... mot D

Mêmes
distances



Espace vectoriel continu






Apprentissage de représentations pour les données textuelles

Du sac de mots aux représentations vectorielles

[2008, 2013, 2016]






Apprentissage de représentations pour les données textuelles

Du sac de mots aux représentations vectorielles

[2008, 2013, 2016]



- Espace sémantique :
significations similaires
 $\Leftrightarrow$
positions proches
- Espace structuré :
régularités grammaticales,
connaissances de base, ...

Distributed representations of words and phrases and their compositionality, [Mikolov et al. NeurIPS 2013](#)




Apprentissage de représentations pour les données textuelles

Du sac de mots aux représentations vectorielles

[2008, 2013, 2016]

Des mots aux tokens

Word Piece statistical split




- Représentation des mots inconnus
- Adaptation aux domaines techniques
- Résistance aux fautes d'orthographe

Enriching word vectors with subword information. [Bojanowski et al. TACL 2017.](#)



Agrégation des représentations de mots : vers l'IA générative


- Génération et représentation
- Nouvelle manière d'apprendre les positions des mots






Architecture Transformer : agrégation à l'état de l'art

Réseau de neurones récurrents :



Transformer :




Attention is all you need, [Vaswani et al. NeurIPS 2017](#)

Sequence to Sequence Learning with Neural Networks, [Sutskever et al. NeurIPS 2014](#)



Un nouveau paradigme de développement depuis 2015

- Jeu de données massif + architecture massive $\Rightarrow$ coût d'entraînement + + +
- Architecture pré-entraînée + zéro-shot / affinage





Au bout du compte: un perroquet stochastique :)

Statistical Modeling of Texts

Texts splitting = tokens

Large Language Models (LLMs), such as GPT-3 and GPT-4, utilize a process called tokenization. Tokenization involves breaking down text into smaller units, known as tokens, which the model can process and understand. These tokens can range from individual characters to entire words or even larger chunks, depending on the model. For GPT-3 and GPT-4, a Byte Pair Encoding (BPE) tokenizer is used. BPE is a subword tok

Token forecasting =
Probabilistic model

Dictionary	Large	0.02
	entire	0.01
	For	0.00
	units	0.00
	...	...
	can	0.00
...	may	0.00
	...	0.09
	...	...
		0.30

Input =
Previous tokens

Language
Model

Output =
Predicted next tokens

Iterative process = writing text

CHATGPT

30 NOVEMBRE, 2022

1 MILLION D'UTILISATEURS EN 5 JOURS


100 MILLIONS À LA FIN JANVIER 2023

1.16 MILLIARD EN MARS 2023



Les ingrédients de chatGPT

0. Transformer + données massives (GPT)



- Grammaire : accord singulier/pluriel, concordance des temps
- Connaissances : entités, nom, lieux, dates, ...



Les ingrédients de chatGPT


1. Plus, c'est mieux ! (GPT)

- + plus de mots en entrée [500 $\Rightarrow$ 2k, 32k, 100k]
- + plus de dim. dans l'espace des mots [500-2k $\Rightarrow$ 12k]
- + plus de têtes d'attention [12 $\Rightarrow$ 96]
- + plus de blocs/couches [5-12 $\Rightarrow$ 96]

175 milliards de paramètres...

Qu'est-ce que cela signifie ?


- $1,75 \cdot 10^{11} \Rightarrow 300 \text{ Go} + 100 \text{ Go}$ (stockage pour l'inférence) $\approx 400 \text{ Go}$
- GPU NVidia A100 = 80 Go de mémoire (=20k€)
- Coût de (1) entraînement : 4,6 millions €





Les ingrédients de chatGPT

2. Suivi du dialogue




- **Données très propres** Données générées/validées/classées par des humains



Les ingrédients de chatGPT


3. Ajustement fin sur des tâches de raisonnement ($\pm$) complexes





Les ingrédients de chatGPT


3. Ajustement fin sur des tâches de raisonnement ($\pm$) complexes





Les ingrédients de chatGPT

4. Instructions + classement des réponses




- Base de données créée par des humains
- Amélioration des réponses

- ... Aussi un moyen d'éviter les sujets sensibles = censure



Un nouveau rapport aux connaissances

■ Bases de données + accès en SQL



Un nouveau rapport aux connaissances

- Bases de données + accès en SQL
- Knowledge Graphs

Barack Obama



44th President of the United States


In office
January 20, 2009 – January 20, 2017

Vice President Joe Biden

Preceded by George W. Bush

Succeeded by Donald Trump

United States Senator from Illinois



Google

quel est l'âge de barack obama

Tous Actualités Images Vidéos courtes Web Finance Livres Plus Outils

Barack Obama > Âge :

64 ans


4 août 1961

Autres questions :



Un nouveau rapport aux connaissances


- Bases de données + accès en SQL
- Knowledge Graphs
- Indexation du web / moteurs de recherche





Un nouveau rapport aux connaissances

- Bases de données + accès en SQL
- Knowledge Graphs
- Indexation du web / moteurs de recherche
- ... Loi de probabilité !




$$p(w_{t+1} | w_t, w_{t-1}, \dots, w_1)$$



GPT-4 & Multimodalité

Fusionner info. texte + image. **Apprendre** l'information conjointement

Exemple du VQA : Visual Question Answering (questions visuelles)



⇒ Rétropropager l'erreur ⇒ modifier les repr. des mots + l'analyse d'image



VQA : Visual Question Answering, arXiv, 2016 , A. Agrawal et al.

LES LIMITES TECHNIQUES



chatGPT et la relation à la vérité


1 **Vraisemblance** = grammaire, accords, concordance des temps, enchaînements logiques...
⇒ Connaissances répétées

2 Prédit le mot le plus **plausible**...
⇒ produit des **hallucinations**

3 Fonctionnement en **hors ligne**

4 chatGPT $\neq$ **graphes de connaissances**

5 Réponses brillantes...
Et erreurs absurdes !
+ on ne peut pas prévoir les erreurs



Exemple : produire une bibliographie

"Variational Recurrent Autoencoders" par Chung et al. (2016) - Cette étude propose une approche VAE pour la modélisation de séquences temporelles en utilisant des réseaux de neurones récurrents et une méthode de maximisation de la vraisemblance pour la phase d'entraînement.

Variational recurrent auto-encoders


"Generative Modeling for Time Series Analysis" par Q.Fabius, J.R.Van Amersfoort - arXiv preprint arXiv:1609.03484



IA générative : comment évaluer la performance ?

Le point critique aujourd'hui

- Comment évaluer par rapport à la vérité terrain ?
- Comment évaluer la confiance du système / la plausibilité de la génération ?






IA générative : comment évaluer la performance ?

Le point critique aujourd'hui


- Comment évaluer par rapport à la vérité terrain ?
- Comment évaluer la confiance du système / la plausibilité de la génération ?



Plausibilité



Entraînement



Test



Do Large Language Models Know What They Don't Know?, Yin et al. , ACL, 2023

Do Deep Generative Models Know What They Don't Know?, Nalisnick et al. , ICLR, 2019



Stabilité / Prévisibilité

- Difficulté à encadrer le comportement
 - Impossible de prédire les bonnes ou mauvaises réponses
- ⇒ Peu ou pas d'utilité dans les jeux vidéo
- ⇒ Difficile de certifier une IA pour des cas d'usage critiques



how old is Obama



Barack Obama was born on August 4, 1961, making him 61 years old as of February 2, 2023.





Stabilité / Prévisibilité

- Difficulté à encadrer le comportement
 - Impossible de prédire les bonnes ou mauvaises réponses
- ⇒ Peu ou pas d'utilité dans les jeux vidéo
- ⇒ Difficile de certifier une IA pour des cas d'usage critiques



how old is obama?



As of 2021, Barack Obama was born on August 4, 1961, so he is 60 years old.




and today?






Explicabilité vs complexité



- Système simple
- Tests exhaustifs des entrées/sorties
- **Prévisible et explicable**



- Grande dimension
- Combinaisons non-linéaires complexes
- **Non prévisible et non explicable**



Explicabilité vs complexité

Interprétabilité vs explication a posteriori

Réseaux de neurones = **non interprétables** (presque toujours)

trop de combinaisons pour être anticipées

Réseaux de neurones = **explicables a posteriori** (presque toujours)



[Accident Uber, 2018]

- Système simple
- Tests exhaustifs des entrées/sorties
- **Prévisible** et **explicable**

- Grande dimension
- Combinaisons non-linéaires complexes
- **Non prévisible** et **non explicable**



Transparence : open source / poids ouverts

- Puis-je le modifier ? Adaptation
- Données d'entraînement utilisées ? Contamination des données
- Quelle ligne éditoriale ou censure est impliquée ? Accès à l'information
- Pourquoi cette réponse ? Explicabilité / interprétabilité

Foundation Model Transparency Index Scores by Major Dimensions of Transparency, 2023


Source: 2023 Foundation Model Transparency Index

	Meta	BigScience	OpenAI	stability.ai	Google	ANTHROPIC	cohere	AI21labs	Inflection	amazon	
	Llama 2	BLOOMZ	GPT-4	Stable Diffusion 2	PaLM 2	Claude 2	Command	Jurassic-2	Inflection-1	Titan Text	Average
Data	40%	60%	20%	40%	20%	0%	20%	0%	0%	0%	20%
Labor	29%	86%	14%	14%	0%	29%	0%	0%	0%	0%	17%
Compute	57%	14%	14%	57%	14%	0%	14%	0%	0%	0%	17%
Methods	75%	100%	50%	100%	75%	75%	0%	0%	0%	0%	48%
Model Basics	100%	100%	50%	83%	67%	67%	50%	33%	50%	33%	63%
Model Access	100%	100%	67%	100%	33%	33%	67%	33%	0%	33%	57%
Capabilities	60%	80%	100%	40%	80%	80%	60%	60%	40%	20%	62%
Risks	57%	0%	57%	14%	29%	29%	29%	29%	0%	0%	24%
Mitigations	60%	0%	60%	0%	40%	40%	20%	0%	20%	20%	26%
Distribution	71%	71%	57%	71%	71%	57%	57%	43%	43%	43%	59%
Usage Policy	40%	20%	80%	40%	60%	60%	40%	20%	60%	20%	44%
Feedback	33%	33%	33%	33%	33%	33%	33%	33%	33%	0%	30%
Impact	14%	14%	14%	14%	14%	0%	14%	14%	14%	0%	11%
Average	57%	52%	47%	47%	41%	39%	31%	20%	20%	13%	



Coûts / Frugalité

The Rise and Rise of A.I. Large Language Models (LLMs) & their associated bots like ChatGPT



David McCandless, Tom Evans, Paul Barton
Information is Beautiful // UPDATED 2nd Nov 23

source: news reports, [LifeArchitecture.ai](https://life-ai.com/)
* = parameters undisclosed // see [the data](https://the-data.com/)

Paramètres

1998	LeNet-5	= 0,06M
2011	Senna	= 7,3M
2012	AlexNet	= 60M
2017	Transformer	= 65M / 210M
2018	ELMo	= 94M
2018	BERT	= 110M / 340M
2019	GPT-2	= 1 500M
2020	GPT-3	= 175 000M
2025	Llama-4	= 2 000 000M



Pas de magie, beaucoup de lacunes


Beaucoup de succès aussi... mais :

⇒ Le LLM (ne) fait (que) ce pour quoi il a été entraîné

En retrait sur:

- Calculs simples
(multiplication, division)
- Génération de noms d'animaux en n syllabes (en cours)
- Jouer aux échecs
- Suivre un raisonnement causal (complexe)
- ...

ATARI 2600 SCORES STUNNING VICTORY OVER CHATGPT



**WHEN YOU UNDERESTIMATE A 1977 CHESS ENGINE...
AND IT HUMBLER YOU IN FRONT OF THE WHOLE INTERNET**