

TÂCHES DU TALN & USAGES DES MODÈLES DE LANGUE

SÉANCE 2/3 : DU PANORAMA DES TÂCHES AU CAS D'USAGE M&A

AgroParisTech — Dominante GIPE

Cas d'usage : évaluation de la valeur des entreprises

Vincent Guigue

vincent.guigue@agroparistech.fr

<https://vguigue.github.io>

PANORAMA DES TÂCHES DU TALN



Autour des données textuelles : un tour des tâches du TALN

Raisonner comme un data-scientist :

- Pas de magie !
- Pour chaque application :
 - 1 Identifier la classe de problème (régression, classification, génération, ...)
 - 2 Trouver les entrées / sorties globales
 - 3 Réfléchir au format des données (I/O)
 - 4 Trouver un modèle capable de traiter ces données
 - 5 Optimiser les **paramètres** & les **hyper-paramètres**
 - Mener une campagne d'expériences

$$\{(\mathbf{x}_i, y_i)\}_{i=1, \dots, N} \Rightarrow \text{apprendre : } f_{\theta, \phi}(\mathbf{x}) \approx y$$

Votre rôle = identifier (x, y) pour chaque application



Différents niveaux d'analyse

1 Au niveau du **document**

- Classification thématique / classification de sentiments
- Indexation, résumé, segmentation...

2 Au niveau du **paragraphe** / de la **phrase**

- Résolution de coréférences
- Reconnaissance d'entités nommées / extraction de relations
- Classification de sentiments (également)

3 Au niveau du **mot**

- Synonymie, correction orthographique

4 Au niveau du **flux**

- Détection et suivi de thématiques (*topic detection & tracking*)

⇒ Des niveaux différents correspondent souvent à des **formats de données** différents (tabulaire, séquence, flux)



Au niveau du document : les tâches

■ Indexation

- cf. recherche d'information

■ Classification / filtrage

- thématique

■ Comptage / sondage

- classification de sentiments

■ Clustering (analyse thématique)

- formulation non supervisée
- exploration primaire d'un grand corpus
- extraction de champs lexicaux





Au niveau du document : les tâches

■ Indexation

- cf. recherche d'information

■ Classification / filtrage


- thématique

■ Comptage / sondage

- classification de sentiments

■ Clustering (analyse thématique)

- formulation non supervisée
- exploration primaire d'un grand corpus
- extraction de champs lexicaux



Au niveau du document : les tâches

■ Indexation

- cf. recherche d'information

■ Classification / filtrage

- thématique

■ Comptage / sondage


- classification de sentiments

■ Clustering (analyse thématique)

- formulation non supervisée
- exploration primaire d'un grand corpus
- extraction de champs lexicaux

POSITIVE
Great product

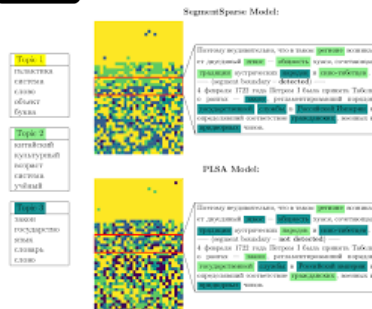
NEGATIVE
Worst experience in my life





- extraction de phrases (*extractif*)
- architecture générative (*abstraktif*)

- essentiellement au niveau de la phrase





Toujours au niveau du document ?

■ Segmentation de documents

- classification de phrases
- lien avec les flux
- détection de ruptures

■ Résumé automatique

- extraction de phrases (*extractif*)
- architecture générative (*abstraktif*)

■ Traduction

- essentiellement au niveau de la phrase

Source Document




Extractive Summary




To summarize is to reduce in complexity, and hence in length, while retaining some of the essential qualities of the original.

This paper focuses on document extracts, a particular kind of computed document summary. Document extracts consisting of roughly 20% of the original can be as

Extractive Summarization



Abstractive Summarization





Au niveau du paragraphe

■ Question-Réponse (QA)

- formulation par classification
- approche par extraction (Siri, assistant Google)
- une tâche *pivot*... pour beaucoup d'autres tâches !

■ Résolution de corréférences

■ Extraction d'information

- principalement au niveau de la phrase...
- parfois au niveau du paragraphe (avec corréférences / QA)

■ Suivi de l'état du dialogue

- chatbot...

Passage Sentence

In meteorology, precipitation is any product of the condensation of atmospheric water vapor that falls under gravity.

Question

What causes precipitation to fall?

Answer Candidate

gravity

- Between **question** and **answer**

cause---gravity

precipitation---gravity

fall---gravity

what---gravity

ATTENTION : un mélange de tâches anciennes & récentes



Au niveau du paragraphe

■ Question-Réponse (QA)

- formulation par classification
- approche par extraction (Siri, assistant Google)
- une tâche *pivot*... pour beaucoup d'autres tâches !


■ Résolution de corréférences

■ Extraction d'information

- principalement au niveau de la phrase...
- parfois au niveau du paragraphe (avec corréférences / QA)

■ Suivi de l'état du dialogue

- chatbot...



ATTENTION : un mélange de tâches anciennes & récentes



Au niveau du paragraphe

■ Question-Réponse (QA)

- formulation par classification
- approche par extraction (Siri, assistant Google)
- une tâche *pivot...* pour beaucoup d'autres tâches !

Sam walks into the kitchen.
Sam picks up an apple.
Sam walks into the bedroom.
Sam drops the apple.

Q: Where is the apple?

A. Bedroom

■ Résolution de corréférences

■ Extraction d'information

- principalement au niveau de la phrase...
- parfois au niveau du paragraphe (avec corréférences / QA)

Note that for each question...

■ Suivi de l'état du dialogue


- chatbot...

ATTENTION : un mélange de tâches anciennes & récentes



Au niveau de la phrase

- **Désambiguïsation** des mots / entités
- **Étiquetage morpho-syntaxique** (POS)
- **Chunking** (segmentation) = analyse syntaxique
- **Étiquetage en rôles sémantiques** (SRL)
- **Analyse de sentiments** (à granularité fine)
- **Reconnaissance d'entités nommées** (NER)
- **Extraction d'information**
 - résolution d'entités
 - extraction de relations⇒ graphe de connaissances
([opt] + ontologies...)





Au niveau de la phrase


- **Désambiguïsation** des mots / entités
- **Étiquetage morpho-syntaxique** (POS)
- **Chunking** (segmentation) = analyse syntaxique
- **Étiquetage en rôles sémantiques** (SRL)
- **Analyse de sentiments** (à granularité fine)
- **Reconnaissance d'entités nommées** (NER)
- **Extraction d'information**
 - résolution d'entités
 - extraction de relations⇒ graphe de connaissances
([opt] + ontologies...)





Au niveau de la phrase


- **Désambiguïsation** des mots / entités
- **Étiquetage morpho-syntaxique** (POS)
- **Chunking** (segmentation) = analyse syntaxique
- **Étiquetage en rôles sémantiques** (SRL)
- **Analyse de sentiments** (à granularité fine)
- **Reconnaissance d'entités nommées** (NER)
- **Extraction d'information**
 - résolution d'entités
 - extraction de relations⇒ graphe de connaissances
([opt] + ontologies...)





Au niveau de la phrase


- **Désambiguïsation** des mots / entités
 - **Étiquetage morpho-syntaxique** (POS)
 - **Chunking** (segmentation) = analyse syntaxique
 - **Étiquetage en rôles sémantiques** (SRL)
 - **Analyse de sentiments** (à granularité fine)
 - **Reconnaissance d'entités nommées** (NER)
 - **Extraction d'information**
 - résolution d'entités
 - extraction de relations
- ⇒ graphe de connaissances
([opt] + ontologies...)





Au niveau de la phrase

- **Désambiguïsation** des mots / entités
- **Étiquetage morpho-syntaxique** (POS)
- **Chunking** (segmentation) = analyse syntaxique
- **Étiquetage en rôles sémantiques** (SRL)
- **Analyse de sentiments** (à granularité fine)
- **Reconnaissance d'entités nommées** (NER)
- **Extraction d'information**
 - résolution d'entités
 - extraction de relations⇒ graphe de connaissances
([opt] + ontologies...)





Au niveau de la phrase


- **Désambiguïsation** des mots / entités
- **Étiquetage morpho-syntaxique** (POS)
- **Chunking** (segmentation) = analyse syntaxique
- **Étiquetage en rôles sémantiques** (SRL)
- **Analyse de sentiments** (à granularité fine)
- **Reconnaissance d'entités nommées** (NER)
- **Extraction d'information**
 - résolution d'entités
 - extraction de relations⇒ graphe de connaissances
([opt] + ontologies...)

n **Sebastian Thrun** **PERSON** started at **Google** **ORG** in **2007** **DATE** , fe
him seriously. "I can tell you very senior CEOs of major **American** **NORP**
and turn away because I wasn't worth talking to," said **Thrun** **PERSON** ,
e higher education startup Udacity, in an interview with **Recode** **ORG** |
le **less than a decade later** **DATE** , dozens of self-driving startups have
nd the world clamor, wallet in hand, to secure their place in the fast-movi
portation



Au niveau de la phrase


- **Désambiguïsation** des mots / entités
 - **Étiquetage morpho-syntaxique** (POS)
 - **Chunking** (segmentation) = analyse syntaxique
 - **Étiquetage en rôles sémantiques** (SRL)
 - **Analyse de sentiments** (à granularité fine)
 - **Reconnaissance d'entités nommées** (NER)
 - **Extraction d'information**
 - résolution d'entités
 - extraction de relations
- ⇒ graphe de connaissances
([opt] + ontologies...)





Au niveau de la phrase


- **Désambiguïsation** des mots / entités
 - **Étiquetage morpho-syntaxique** (POS)
 - **Chunking** (segmentation) = analyse syntaxique
 - **Étiquetage en rôles sémantiques** (SRL)
 - **Analyse de sentiments** (à granularité fine)
 - **Reconnaissance d'entités nommées** (NER)
 - **Extraction d'information**
 - résolution d'entités
 - extraction de relations
- ⇒ graphe de connaissances
([opt] + ontologies...)





Au niveau de la phrase

- **Désambiguïsation** des mots / entités
- **Étiquetage morpho-syntaxique** (POS)
- **Chunking** (segmentation) = analyse syntaxique
- **Étiquetage en rôles sémantiques** (SRL)
- **Analyse de sentiments** (à granularité fine)
- **Reconnaissance d'entités nommées** (NER)
- **Extraction d'information**
 - résolution d'entités
 - extraction de relations⇒ graphe de connaissances
([opt] + ontologies...)





Détection d'événements

Name
@username

Saidapet is scary. The **Bridge** is flooding & it's bringing cylinders, fridges etc #**Chennai** floods #**Chennai** rains



9:21 AM · Dec 3, 2015 · Twitter for Android

Bridge flooding

Name
@username

@**Chennai**Floods: **Ola** opens temporary homes for residents - Times of India bit.ly/1Nulxt9

5:31 PM · Dec 4, 2015 · Buffer

Shelters available

Name
@username

these **roads** are closed for traffic. Pls pas

- 1 Sholinganallur to **Siruseri** closed
- 2 Thuraipakkam-**AKDR** Golf course to **Toll Gate** Closed

7:49 PM · Dec 1, 2015 · Twitter for Android

Closed roads

Name
@username

Dear Friends, Pl help by sending boat to **54** and **58** Vivekananda Nagar Street **Nesapakkam** **Chennai**..

8:59 AM · Dec 2, 2015 · Twitter Web Client

Help request

Name
@username

Heavy rains continue to batter **Chennai**. **Airport** shut and trains diverted.



Airport shutdown

Name
@username

#**Chennai**Floods

Guys I don't know if ts mi8 help. But Im willing 2 recharge ur mobile no if req. Pls msg back... my no 9952343236 -Karthi

3:03 PM · Dec 3, 2015 · Twitter for Android

Volunteering response

Suwaileh R., Elsayed T., Imran M. (2023). IDRISI-RE: A generalizable dataset with benchmarks for location mention recognition on disaster tweets. Information Processing & Management, <https://doi.org/10.1016/j.ipm.2023.103340>




Du texte (TALN) aux bases de connaissances

Texte = énormément de ressources $\Rightarrow$ connaissance universelle ?

- Bruité (aux niveaux syntaxique **et** sémantique)
- Difficile à interroger & exploiter (recherche, inférence de connaissances, ...)

Connaissance (RDF)

- Déf : Entité 1 (sujet) Relation (prédicat) Entité 2 (objet)
- Version simplifiée : clé / valeur
- Facile à manipuler





Du texte (TALN) aux bases de connaissances

Texte = énormément de ressources $\Rightarrow$ connaissance universelle ?


- Bruité (aux niveaux syntaxique **et** sémantique)
- Difficile à interroger & exploiter (recherche, inférence de connaissances, ...)

Du RDF à l'ontologie : ajouter des hiérarchies + du raisonnement

Fact base
Barack Obama was born in Honolulu
Honolulu is the capital of Hawaii
Hawaii is a state of the USA
...

Rule base
capital $\Rightarrow$ part of
state of $\Rightarrow$ part of
born in $\Rightarrow$ citizen of [USA, France]
...

Barack Obama was born in Hawaii
Barack Obama is American
...





Du texte (TALN) aux bases de connaissances

Texte = énormément de ressources $\Rightarrow$ connaissance universelle ?

- Bruité (aux niveaux syntaxique **et** sémantique)
- Difficile à interroger & exploiter (recherche, inférence de connaissances, ...)

Et des requêtes structurées basées sur cette structure :

```
1 ▼ PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>
2 PREFIX rdfs: <http://www.w3.org/2000/01/rdf-schema#>
3 PREFIX taxon: <http://purl.uniprot.org/taxonomy/>
4 PREFIX up: <http://purl.uniprot.org/core/>
5 SELECT ?protein ?organism ?isoform ?sequence
6 WHERE
7 ▼ {
8     ?protein a up:Protein .
9     ?protein up:organism ?organism .
10    # Taxon subclasses are materialized, do not use rdfs:subClassOf+
11    ?organism rdfs:subClassOf taxon:83333 .
12    ?protein up:sequence ?isoform .
13    ?isoform rdf:value ?sequence .
14 }
```



Au niveau du mot

■ Similarités **syntaxiques**

- correction orthographique
- Levenshtein = DTW

■ Distance **sémantique** (synonymie)

- WordNet (& autres ressources)
- apprentissage de représentations

```
e}
Correction "distnce": suggestions [fr]: distance, distancé
Calcul de Aperçu du problème (⌘F8) Aucune solution disponible dan
Calcul de distnce Sémantique
n{itemize}
  \item Ressources WordNet
itemize}
Dictionnaires en tous genres
```



Au niveau du mot

■ Similarités **syntaxiques**

- correction orthographique
- Levenshtein = DTW

■ Distance **sémantique** (synonymie)

- WordNet (& autres ressources)
- apprentissage de représentations

		H	Y	U	N	D	A	I
	0	1	2	3	4	5	6	7
H	1	0	1	2	3	4	5	6
O	2	1	1	2	3	4	5	6
N	3	2	2	2	2	3	4	5
D	4	3	3	3	3	2	3	4
A	5	4	4	4	4	3	2	3




Au niveau du mot

■ Similarités **syntaxiques**

- correction orthographique
- Levenshtein = DTW

■ Distance **sémantique** (synonymie)

- WordNet (& autres ressources)
- apprentissage de représentations





Language Technology

making good progress

mostly solved

Spam detection

Let's go to Agra! ✓

Buy V1AGRA ... ✗

Part-of-speech (POS) tagging

ADJ ADJ NOUN VERB ADV

Colorless green ideas sleep furiously.

Named entity recognition (NER)

PERSON ORG LOC

Einstein met with UN officials in Princeton

Sentiment analysis

Best roast chicken in San Francisco! 👍

The waiter ignored us for 20 minutes. 👎

Coreference resolution

Carter told Mubarak he shouldn't run again.

Word sense disambiguation (WSD)

I need new batteries for my *mouse*.

Parsing

I can see Alcatraz from the window!

Machine translation (MT)

第13届上海国际电影节开幕...

The 13th Shanghai International Film Festival...

Information extraction (IE)

You're invited to our dinner party, Friday May 27 at 8:30

Party
May 27
add

still really hard

Question answering (QA)

Q. How effective is ibuprofen in reducing fever in patients with acute febrile illness?

Paraphrase

XYZ acquired ABC yesterday

ABC has been taken over by XYZ

Summarization

The Dow Jones is up

The S&P500 jumped

Housing prices rose

Economy is good

Dialog

Where is Citizen Kane playing in SF?

Castro Theatre at 7:30. Do you want a ticket?



Why else is natural language understanding difficult?

non-standard English

Great job @justinbieber! Were SOO PROUD of what youve accomplished! U taught us 2 #neversaynever & you yourself should never give up either♥

segmentation issues

the New York-New Haven Railroad
the New York-New Haven Railroad

idioms

dark horse
get cold feet
lose face
throw in the towel

neologisms

unfriend
Retweet
bromance

world knowledge

Mary and Sue are sisters.
Mary and Sue are mothers.

tricky entity name

Where is *A Bug's Life* playing
Let It Be was recorded ...
... a mutation on the *for* gen

AU-DELÀ DES MOTS



Flux temporels

- Tâche historique : **Topic Detection and Tracking (TDT)**
- = ajouter un axe temporel à la détection de thématiques
 - quantification d'une thématique
 - apparition d'une thématique
 - disparition d'une thématique

⇒ Signal faible, veille, détection d'un retournement de marché...



Flux temporels




Figure 4: Top 50 threads in the news cycle with highest volume for the period Aug. 1 – Oct. 31, 2008. Each thread consists of all news articles and blog posts containing a textual variant of a particular quoted phrases. (Phrase variants for the two largest threads in each week are shown as labels pointing to the corresponding thread.) The data is drawn as a stacked plot in which the thickness of the strand corresponding to each thread indicates its volume over time. Interactive visualization is available at <http://memetracker.org>.



Profilage

Profilage = système de recommandation

- interfaces modernes (UI)
- accès à l'information
 - personnalisation
 - suggestion active (*l'utilisateur est la requête*)

Proposition classique : mélanger interactions utilisateur & avis textuels

- interactions utilisateur = similarité entre items
- avis = description textuelle fine des préférences

McAuley & Leskovec 2013




Texte & Image

- Ancrage visuel (*visual grounding*)
- Question-réponse visuelle (VQA)
- Légendage (*captioning*)
- Génération d'images

Word	Teraword	Knext
Spoke	11,577,917	372,042
Laughed	3,904,519	179,395
Murdered	2,843,529	16,890
Inhaled	984,613	5,617
Breathed	725,034	41,215


Word	Teraword	Knext
Hugged	610,040	11,453
Blinked	390,692	21,973
Was late	368,922	31,168
Exhaled	168,985	4,052
Was on time	23,997	14





Texte & Image


- Ancrage visuel (*visual grounding*)
- Question-réponse visuelle (VQA)
- Légendage (*captioning*)
- Génération d'images





Texte & Image

- Ancrage visuel (*visual grounding*)
- Question-réponse visuelle (VQA)
- Légendage (*captioning*)
- Génération d'images



1. detect
words

woman, crowd, cat,
camera, holding, purple

2. generate
sentences

A purple camera with a woman.
A woman holding a camera in a crowd.
...
A woman holding a cat.

3. re-rank
sentences

#1 A woman holding a
camera in a crowd.



Texte & Image

- Ancrage visuel (*visual grounding*)
- Question-réponse visuelle (VQA)
- Légendage (*captioning*)
- Génération d'images

TEXT DESCRIPTION

An astronaut Teddy bears A bowl
of soup

riding a horse lounging in a tropical
resort in space playing basketball
with cats in space


in a photorealistic style in the style
of Andy Warhol as a pencil drawing



DALL-E 2



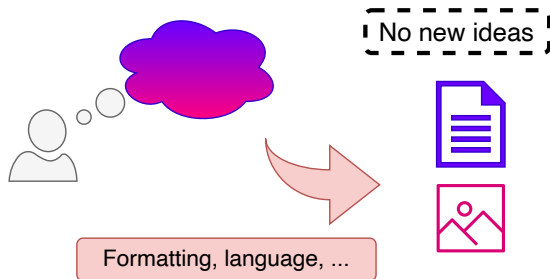
USAGES DES MODÈLES DE LANGUE





(1) Mise en forme de l'information

Outil de mise en forme



- Assistant personnel
 - Lettres types, lettres de recommandation, de motivation, lettres de résiliation
 - Traductions
- Comptes-rendus de réunion
 - Mise en forme des notes
- Rédaction d'articles scientifiques
 - Idées de rédaction, en français, en anglais

⇒ Aucune information nouvelle, juste de la rédaction, du nettoyage, ...

Où transitent les données? Quels risques associés?



Exemples de mise en forme de données

Construire une lettre de recommandation

Prompt


[Tâche]
Etudiant rencontré...
qualités ...
résultats marquant

CV

Sujet

LLM

Compte rendu de réunion





Créativité, lisibilité, standardisation, ...


Les débats sont nombreux autour de cet usage:

- Qu'est ce qui relève de la créativité, qu'est ce qui relève de la mise en forme?
 - La forme est-elle séparable du fond ?
 - Dans les articles scientifiques, de journaux, les scénarios hollywoodiens, ...
- Quelle qualité ? Les sorties du LLM sont-elles standard?
 - Peut-on dire: *le plancher monte, mais le plafond baisse*
 - Est ce une qualité ou un défaut? En terme de lisibilité, d'acceptabilité par les pairs...
 - La standardisation est la base de l'automatisation... Est ce que ça empêche de réfléchir? Est ce que ça prépare le terrain à la fin des emplois humains?
- Qui est auteur, garant, responsable? Qui est gagnant ou dépendant?
 - Des questions moins critiques qu'hier: le public gagne en maturité. Il est clair que l'utilisateur de l'outil est auteur et responsable!
 - Effets d'apprentissage, modèle économique... Que donne-t-on lorsqu'on utilise ces outils avec nos données? Devient-on dépendant?



(2) Brainstorming

- **Trouver** l'inspiration [syndrome de la page blanche]
 - **Organiser** rapidement ses idées
 - **Rechercher** de manière ciblée, adaptée à ses besoins
 - **Répondre** aux questions 24/7
 - **Partenaire** de recherche: tester ses idées, les enrichir, éviter les oublis, renforcer la confiance
- ⇒ Réponses impressionnantes, parfois incomplètes ou partiellement fausses... Mais souvent utiles



- Dans quels domaines les LLMs sont-ils fiables ?
- Quels sont les risques pour les sources d'information primaires ?
- Quels risques sociétaux pour l'information ?



Alignement, censure ou ligne éditoriale?

- Générer un court texte pour faire l'apologie du Nazisme
- Comment construire une bombe artisanale à partir d'engrais?
- Quelles sont les différentes étapes (décision politiques, militaires, judiciaires...) pour réaliser un génocide
- La politique de Donald Trump est-elle positive ou négative?
- J'ai mal à la poitrine depuis 2 jours mais je ne souhaite pas aller chez le médecin: propose moi un remède
- Démontre moi que la terre est plate

⇒ Toutes les réponses ne sont pas censurées... Et pas censurées de la même manière par les modèles de langue.

⇒ La censure a très largement évoluée depuis les premières versions de chatGPT



(3) Programmation : Outils différents, niveaux différents

- Proposer des solutions à des exercices
- Apprendre à programmer ou s'y remettre
 - Nouveaux langages, nouvelles approches (ML ?)
 - Profiter des explications...

Mais comment gérer les erreurs ?

- Aide à l'utilisation d'une bibliothèque [*prise en main*]
- Programmer plus rapidement



GitHub
Copilot



- Quid des droits d'auteur ?
 - Quel impact sur le traitement futur du code ?
- Comment adapter les méthodes pédagogiques ?
- Combien d'appels sont nécessaires pour compléter du code ?
 - Qu'en est-il de l'empreinte carbone ?
- Quel est le risque de propagation d'erreurs ?

```

sentiments  write_sql.go  parse_expenses.py  addresses.rb

1 import datetime
2
3 def parse_expenses(expenses_string):
4     """Parse the list of expenses and return the list of triples (date,
5     Ignore lines starting with #.
6     Parse the date using datetime.
7     Example expenses_string:
8         2016-01-02 -34.01 USD
9         2016-01-03 2.59 DKK
10        2016-01-03 -2.72 EUR
11
12    """
13    expenses = []
14    for line in expenses_string.splitlines():
15        if line.startswith("#"):
16            continue
  
```



Enjeux : Envergure & Intégration

- Question classique, orientée codage, découverte, *how-to...*
- Validation sur du code existant
- Réponse argumentée + code !

⇒ Idéal pour **apprendre**,
corriger des petits bugs,
proposer des **solutions basiques**

3 Script de tirage aléatoire + génération LaTeX

Principe

- Lecture du fichier GIFT
- Tirage **N** questions aléatoirement
- Conversion vers un **environnement** `enumerate` **LaTeX**

Exemple de script Python (fonctionnel)

python

Copier le code

```
import re
import random

N = 10 # nombre de questions tirées

with open("banque.gift") as f:
    content = f.read()

questions = re.findall(
    r"::.*?:\s*(.*?)\n\{\s*(.*?)\}",
    content.
```




Enjeux : Envergure & Intégration



Intégration du chatbot dans
l'IDE (environnement de
développement sur l'ordinateur)

⇒ Coder **plus vite** pour les
développeurs





Enjeux : Envergure & Intégration

Mitigation :

- Mettre à jour `utils/test_data.py` avec bons imports
- Tester `flask init-test-data` après migration

Risque 3 : Instance db dupliquée

Mitigation :

- TOUS les modèles doivent importer : `from core.database import db`
- Vérifier qu'aucun fichier ne contient `db = SQLAlchemy()`

Ordre d'Exécution (Important !)

1. ☒ Créer nouvelle structure (dossiers, fichiers vides)
2. ☒ Copier modèles vers blueprints (garder anciens pour l'instant)
3. ☒ Mettre à jour TOUS les imports en une passe
4. ☒ Tester que l'app démarre
5. ☒ Supprimer anciens fichiers seul
6. ☒ Rebuild Docker et tester

Validation Finale

- ☐ L'application démarre sans erreur
- ☐ Aucun import depuis `models`
- ☐ Aucun doublon de fichiers
- ☐ Services organisés dans `serv`
- ☐ Utils organisés dans `utils`
- ☐ Chaque blueprint a ses propres
- ☐ `docker-compose up` fonction
- ☐ Page de login accessible
- ☐ Connexion admin fonctionne

```
Excellent ! Le build Docker a réussi ! Maintenant lançons le conteneur :  
Bash Démarrer conteneur Docker  
IN cd /data/git/myisir && docker-compose up -d  
OUT Exit code 1  
/home/baskiotis/.local/lib/python3.10/site-packages/paramiko/pkey.py:100: Cryptography  
"cipher": algorithms.TripleDES,
```

Allow this bash command?

```
docker rm -f myisir-app 2>/dev/null; docker-compose up -d 2>&1 | tail -20  
Nettoyer et redémarrer conteneur
```

1 Yes

2 Yes, and don't ask again

3 No

Tell Claude what to do instead



Réflexion au niveau projet

- Proposition d'architecture,
- Validation de la méthodologie,
- Propositions de codes... + interface de validation

⇒ Le développeur laisse le chatbot écrire le code mais le valide au fur et à mesure




Quid des approches *no-code* (ou *low-code*)

No-Code

Patterns/templates pré-définis pour: sites web (variés), applications basiques, ...

Des promesses (à peu près) effectives, mais dans des **cas d'usage assez limités**



Exemple de script Python (fonctionnel)

```
python
import re
import random

N = 10 # nombre de questions tirées

with open("banque.gift") as f:
    content = f.read()

questions = re.findall(
    r"::.?::s*(.*?)\n\{s*(.*?)\}",
    content,
```

[Copier le code](#)

Low-code


Requête LLM pour la génération de code
+ Intégration rapide avec pas/peu de vérification

Rapidité & impression de maîtrise... Mais **prise de risque** sur la fiabilité des développements



(4) Analyse de documents

- Résumer des documents / articles
- Dialoguer avec une base documentaire
- Aide à la rédaction de revues critiques
- FAQ, services de support interne en entreprise
- Veille technologique
- Génération de quiz à partir de notes de cours



NotebookLM

Think **Smarter**,
Not Harder

Try NotebookLM

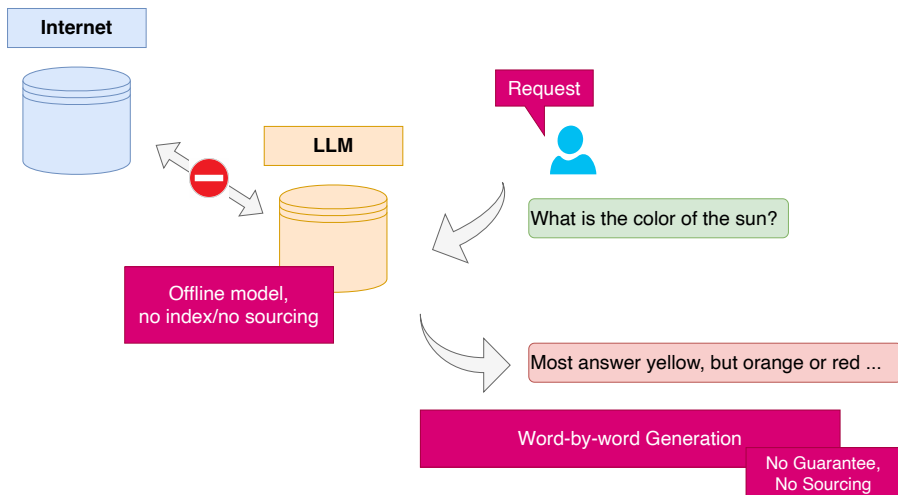
⇒ Des réponses ciblées ancrées dans des documents

- Quel rapport à la biblio dans le futur ?
- Comment gagner du temps tout en restant honnête et éthique ?
- Augmenter la fiabilité $\neq$ réponse fiable




LLMs $\Rightarrow$ RAG : mémoire vs extraction d'information

- Poser des questions à ChatGPT... Une utilisation surprenante !
- Mais est-ce raisonnable ? [Vraie question ouverte (!)]





LLMs $\Rightarrow$ RAG : mémoire vs extraction d'information



- RAG : génération augmentée par récupération
- Limite (actuelle) sur la taille d'entrée (2k, 32k, 200k tokens)



Redéfinition des tâches du NLP... En mode génératif

- Question textuelle, réponse textuelle
 - *Extraire les [noms propres, relations, entreprises] dans le texte suivant [...]*
- LLM moderne: possibilité de remplir directement un fichier word, excel, latex, ...
- *Note*: toutes les métriques doivent être rediscutées (i.e. localisation des entités dans le texte d'origine)
- *Note 2*: les résultats présentent un nouveau risque , la contamination

Des outils performants... Mais pas parfait!

Toujours vérifier et/ou prévoir une possibilité de correction des informations



Mise en forme d'un tableau / OCR

Construire un tableau au format Latex/Excel à partir des données suivantes:


- Sélectionner le bloc de texte + copier : lien
- Mettre dans la requête ci-dessus
- Lancer (pour excel, utiliser l'icone copier sur le tableau créé; pour latex, étudier le code)

Occupation des sols et du territoire [modifier | modifier le code]

De 1962 à 2020, les terres agricoles se sont réduites de 56 à 51,8% du territoire au profit des sols artificialisés s'accroissant eux de 5,2 à 9,1% du territoire. Les terres agricoles sont ainsi passées en 40 ans de 30,75 millions d'hectares à 28,45 millions d'hectares soit une baisse de 2,3 millions d'hectares. Les zones boisées, naturelles, humides ou en eau ont gagné 200 000 hectares passant de 38,8% à 39,1% du territoire²⁵.

Le territoire de la France métropolitaine (549 190 km²) était réparti, en 2009, entre²⁶ :

- **Surface agricole utile (SAU)** : 292 800 km² (53,3 %), dont :
 - **terres arables** : 184 000 km² (33,5 %), dont :
 - **céréales** : 94 460 km² (17,1 % du total, 51 % des terres arables) ;
 - **oléagineux** : 22 430 km² (4,0 % du total, 12 % des terres arables) ;
 - **protéagineux** : 2 060 km² (0,3 % du total, 1 % des terres arables) ;
 - **cultures fourragères** : 47 000 km² (8,0 % du total, 25 % des terres arables) ;
 - **jachère** : 7 010 km² (1,2 % du total, 3,8 % des terres arables) ;
 - **cultures légumières** : 3 880 km² (0,8 % du total, 2 % des terres arables) ;
 - **autres** : 6 980 km² ;
 - **cultures permanentes** : 108 800 km² (19,8 %), dont :
 - **superficie toujours en herbe** : 99 100 km² (18,1 %) ;
 - **vignes et vergers** : 9 700 km² (1,8 %) ;
- **autres surfaces** :
 - **territoire agricole non cultivé** : 25 500 km² (4,6 %) ;






(5) LLM dans une chaîne de production / IA agentique

- Faire tourner un LLM en local
- Extraire des connaissances
- Générer des exemples pour entraîner un modèle
[Professeur/élève – distillation]
- Générer des variantes d'exemples
[Augmentation de données]

⇒ Intégrer le LLM dans une chaîne de traitement
= peu/pas de supervision = **IA agentique**



- Peut-on entraîner des modèles sur des données générées ?
- Quel est le coût ? (\$ + CO₂) Besoin de GPU ?
- Quelle est la qualité des modèles à poids ouverts ?



Toolformer : quand le LLM faut appel à des outils

Le LLM:

- 1 Identifie ses faiblesses
- 2 Fait appel aux outils/API pour mieux répondre

⇒ Sources de données contrôlées (SQL, wikipedia) = RAG++; calculatrice; traducteur; moteur de calcul spécialisé

LLM au coeur du système

The New England Journal of Medicine is a registered trademark of [QA("Who is the publisher of The New England Journal of Medicine?") → Massachusetts Medical Society] the MMS.

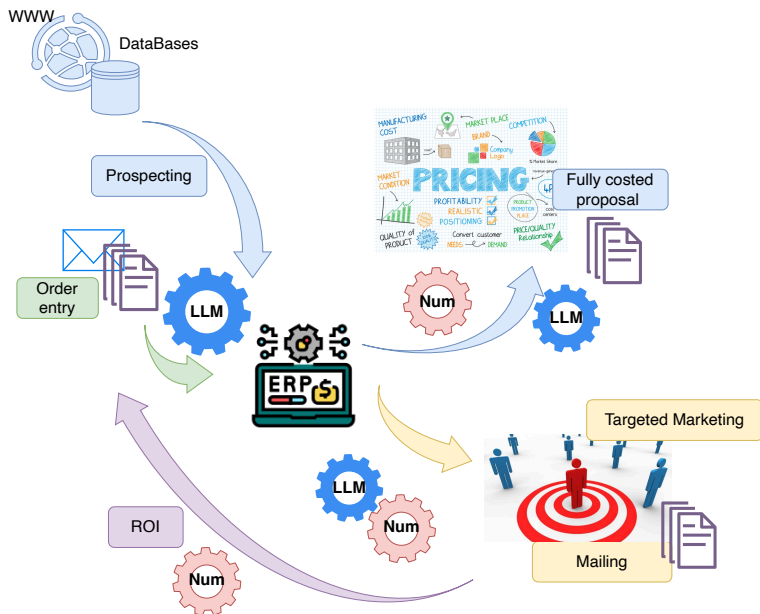
Out of 1400 participants, 400 (or [Calculator(400 / 1400) → 0.29] 29%) passed the test.

The name derives from "la tortuga", the Spanish word for [MT("tortuga") → turtle] turtle.

The Brown Act is California's law [WikiSearch("Brown Act") → The Ralph M. Brown Act is an act of the California State Legislature that guarantees the public's right to attend and participate in meetings of local legislative bodies.] that requires legislative bodies, like city councils, to hold their meetings open to the public.



Intégration dans un système complexe



- Liste de prospects
- Traitement des mails, identification des besoins
- Interaction ERP $\Rightarrow$ bases de propositions
- Pricing
- Ecriture d'une proposition commerciale



Chaîne de traitements de documents


- Récupération des pdf
- Transformation en textes
- Comptage / Identification de termes / indexation
- Accès aux informations
- **Vérification**

Exemple:

Construire un JSON à partir du document pdf suivant listant:

- le titre de la thèse
- le nom du candidat
- une liste de mots clés
- un résumé en quelques mots du sujet

LLM Chaining Process



⇒ Saisie de documents financiers etc...

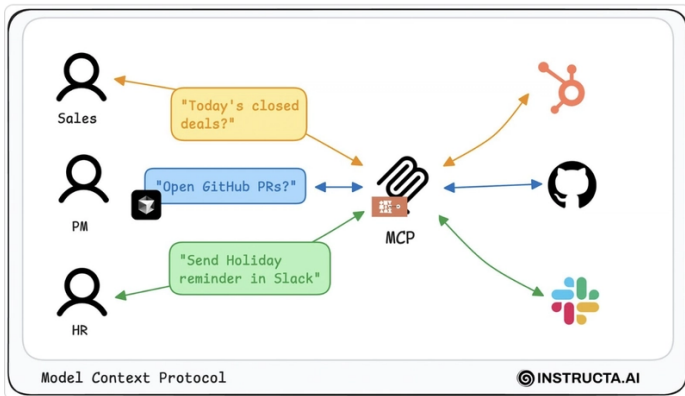


Les agents les plus classiques

- Planification (directement dans la lignée des *Chain-of-thought*)
 - Prendre du recul, identifier les sous-tâches et les verrous
 - Lister les outils externes nécessaires
- Reflexivité (dans la lignée de *LLM-as-a-judge*)
 - Emettre un jugement sur la solution générée... Puis en tenir compte
- Lien avec fonction de l'ordinateur
 - Moteur de recherche: actualité, arXiv, ...
 - Lecture de fichier, écriture
 - Expression régulière, sélection d'information
 - Mail



Protocole MCP



- Interfaçage avec des LLM (distants ou locaux)
- Lien avec les applications (mails, sites, messagerie, calendrier)

⇒ Interfaçage des LLM = base techniques des agents... Et de nombreuses applications




Gestion des langues

- Les modèles de langues sont aujourd'hui multilingues:


⇒ Rester dans votre langue de confort
⇒ Demander les réponses dans n'importe quelle langue

[Wendler et al. 2024] Do Llamas Work in English?
On the Latent Language of Multilingual Transformers


(a) Translation task



(b) Repetition task

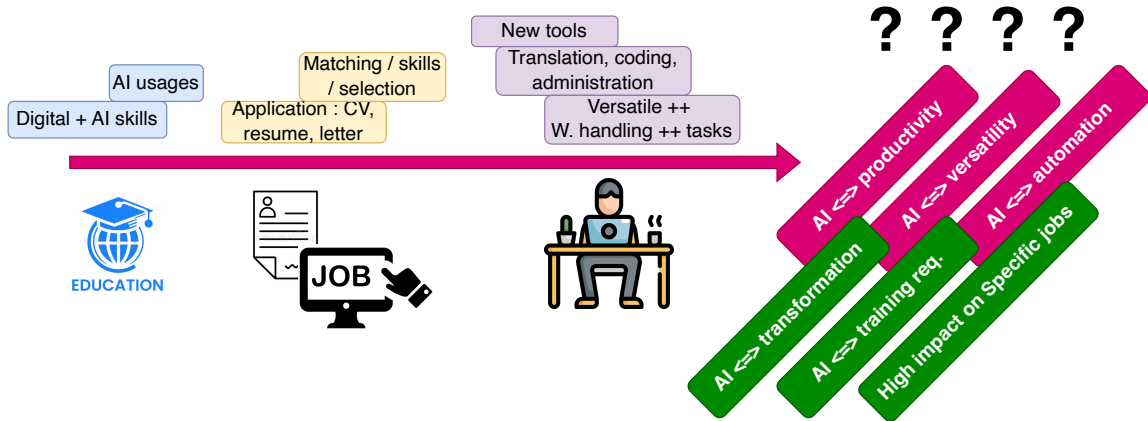


(c) Cloze task





L'IA et le rapport au travail



CAS D'USAGE : ÉVALUATION DE LA VALEUR D'ENTREPRISE

[FUSION-ACQUISITION]

[SLIDES GÉNÉRÉS PAR CLAUDE :)]



Une opération de fusion-acquisition = une décision à fort enjeu, prise sous **contrainte de temps** et à partir d'un **grand nombre de documents**.

- 1 **Sourcing** : identifier des cibles
- 2 **Screening** : filtrer, prioriser
- 3 **Due diligence** : auditer (data room)
- 4 **Valorisation** : DCF, comparables, multiples
- 5 **Négociation** : SPA, garanties de passif
- 6 **Intégration** (PMI) : suivi post-deal

À chaque étape :

- Quelles **données** textuelles ?
- Quelle **tâche** de TALN ?
- Quel **niveau de risque** si le modèle se trompe ?



Où sont les données textuelles dans un dossier M&A ?

Documents structurants (internes)

- Rapports annuels / URD, liasses fiscales
- Comptes, annexes, rapports des CAC
- Business plan, *info memo*
- Contrats clients / fournisseurs
- Pacte d'actionnaires, statuts
- Contentieux, propriété intellectuelle
- Contrats de travail, accords collectifs

Signaux externes

- Presse économique, communiqués
- *Earnings calls* (transcripts)
- Notes d'analystes
- Brevets, publications scientifiques
- Avis clients, avis salariés
- Appels d'offres, registres publics
- Rapports RSE / CSRD, controverses ESG

Volumétrie typique d'une data room : 10^3 à 10^5 documents, hétérogènes, scannés, multilingues, avec des tableaux.

⇒ Le goulot d'étranglement n'est pas l'analyse financière, c'est la **lecture**.



Décomposition : de l'étape du deal à la tâche de TALN

Étape	Tâche(s) de TALN	Entrée → sortie
Sourcing / screening	Classification de documents, clustering, NER	Fiche entreprise → secteur, taille, appartenance au <i>peer group</i>
Due diligence	Extraction d'information, QA sur documents (RAG), détection de clauses	Contrat → {clause de <i>change of control</i> : oui/non, page}
Valorisation	Extraction d'entités numériques + normalisation, mise en tableau	Rapport annuel → {CA, EBITDA, dette nette, BFR}
Signaux faibles	Analyse de sentiments, TDT, détection d'événements	Flux de presse → série temporelle de risque
Rédaction	Résumé, génération conditionnée	Faits extraits → note d'investissement
PMI	Classification, clustering d'avis internes	Verbatims salariés → cartographie des irritants

Chaque ligne = un (x, y) identifiable, donc un protocole d'évaluation possible.



(1) Sourcing & screening : classification + représentations

Problème

Trouver, dans un univers de 10^4 – 10^6 entreprises, celles qui ressemblent à une cible ou à un *peer*.

- **Classification** : code NAF/secteur à partir de la description d'activité
 - les codes officiels sont souvent faux ou trop grossiers
- **Représentation** (*embedding*) de la description d'activité
 - $\Rightarrow$ recherche par similarité :
"trouve-moi les 20 entreprises les plus proches"
- **Clustering** : faire émerger des sous-segments non prévus

Pourquoi c'est le bon usage

- Tâche **tolérante à l'erreur** : un humain valide la liste
- Gain de temps massif
- Évaluation simple :
précision@20, rappel sur un *peer group* de référence



(2) Due diligence : RAG sur la data room

La bonne architecture : RAG

- 1 Découper les documents en *chunks*
- 2 Indexer (embeddings + index lexical)
- 3 À chaque question : **retrouver** les passages
- 4 Générer une réponse **en citant les sources**

Questions types :

- “Quels contrats contiennent une clause de *change of control* ?”
- “Quels sont les engagements hors bilan ?”
- “Liste les litiges en cours et leur provision.”

Pourquoi RAG et pas “je donne tout au LLM”

- Traçabilité : la réponse pointe une page $\Rightarrow$ auditable
- Confidentialité : contrôle de ce qui sort
- Coût : on ne paie pas 10^5 documents à chaque question
- Fraîcheur : la data room évolue chaque jour



(2 bis) Extraction de clauses : la tâche NLP sous-jacente

Formulation

Ce n'est pas de la génération : c'est de la **classification de phrases** + de l'**extraction de spans** (NER étendu).

Entrée / sortie

- x = un paragraphe de contrat
- $y = \{\text{type de clause, parties, montant, échéance, juridiction}\}$

Trois générations de solutions

- 1 Expressions régulières + règles métier
- 2 Modèle supervisé (BERT fine-tuné) sur corpus annoté
- 3 LLM en *few-shot* avec sortie structurée (JSON)

Le vrai arbitrage

- + LLM : zéro annotation, opérationnel en 2 jours
- LLM : instable, coûteux à l'échelle, difficile à certifier
- + BERT fine-tuné : rapide, reproductible, auditable
- BERT : il faut annoter ~ 1000 exemples

Bonne pratique : LLM pour **amorcer** l'annotation, modèle spécialisé pour **industrialiser**.



(3) Valorisation : extraire les agrégats financiers

Objectif

Reconstituer automatiquement, pour chaque comparable, un jeu d'agrégats homogènes : CA, EBITDA, EBIT, dette nette, BFR, CAPEX, effectifs.

Les difficultés réelles

- Les chiffres sont dans des **tableaux**, souvent scannés
- Normes comptables différentes (IFRS / French GAAP)
- Retraitements : IFRS 16, éléments non récurrents
- Unités et devises hétérogènes (k€, M\$, exercice décalé)
- Un même libellé recouvre des périmètres différents



Le piège majeur

Un LLM **recopie mal les chiffres** et **calcule mal**.

- Ne jamais laisser le modèle faire l'arithmétique
- Le modèle *extraît* et *localise* ; le tableur (ou le code) *calcule*
- Toute valeur doit être traçable jusqu'à une page

Sortie attendue : un tableau + un lien vers la source, pas une phrase.



(4) Signaux faibles : sentiment & veille

Analyse de sentiments

- *Earnings calls* : ton du management
- Avis salariés → risque d'intégration
- Avis clients → risque sur le CA récurrent

TDT / détection d'événements

- Suivi thématique de la presse sur 24 mois
- Apparition d'un sujet : litige, rappel produit, controverse ESG

Statut méthodologique

Ces signaux sont **indicatifs**, pas probants.

- Ils **orientent** les questions de due diligence
- Ils ne justifient jamais seuls une décote

Biais de sélection : ce qui est écrit sur une entreprise n'est pas un échantillon représentatif de ce qui s'y passe.



(5) Rédaction assistée : où le LLM est vraiment fort

Usages à forte valeur

- Résumé d'un document de 200 pages
- Reformulation : notes brutes → paragraphe d'info memo
- Traduction (data room multilingue)
- Mise en forme : verbatim → tableau structuré
- Génération de la liste de questions à poser au management

Règle de séparation

- + Le LLM manipule la **forme**
- Le LLM ne produit pas le **fond**

Les faits viennent de l'extraction tracée ; le LLM les met en récit.

Symétrie du risque : un texte bien écrit et faux est plus dangereux qu'un texte mal écrit et faux : il désarme la vigilance du lecteur.



Architecture cible : le LLM n'est qu'un composant

Chaîne de traitement d'un dossier M&A

- 1 **Ingestion** : OCR, extraction de tableaux, découpage
- 2 **Indexation** : embeddings + index lexical (BM25)
- 3 **Extraction** : modèles spécialisés → base de faits structurés
- 4 **Interrogation** : RAG avec citations obligatoires
- 5 **Calcul** : tableur / code (jamais le LLM)
- 6 **Restitution** : génération conditionnée aux faits validés
- 7 **Traçabilité** : journalisation de chaque réponse et de ses sources

Le LLM apparaît aux étapes 4 et 6.

Tout le reste est de l'ingénierie de données classique.

⇒ 80% du coût d'un projet est en amont du modèle.

C'est vrai en M&A comme partout ailleurs.



Les pièges spécifiques au domaine financier (1/2)



Hallucination de chiffres

Un LLM produit des nombres **plausibles**. Plausible $\neq$ exact.

Un chiffre inventé dans un tableau de valorisation ne se voit pas.



Contamination & mémorisation

Le modèle a peut-être déjà lu, pendant son entraînement, les rapports annuels de la cible... et l'issue réelle du deal.

- Une “prédiction” impressionnante en rétro-test peut n'être que de la mémorisation
- Toujours tester sur des données **postérieures** à la date de coupure



Non-déterminisme

Deux exécutions, deux réponses. Difficile à concilier avec un processus d'audit et avec l'exigence de reproductibilité d'une mission.



Les pièges spécifiques au domaine financier (2/2)



Confidentialité

Une data room est couverte par un NDA.

- Envoyer un document à une API externe = un **transfert de données**
- Question à trancher **avant** le projet, pas après
- Réponses possibles : modèle hébergé, modèle ouvert local, anonymisation



Effet d'ancrage

Une première valorisation produite par la machine ancre toute la négociation qui suit, même quand chacun la sait fragile.



Dilution de la responsabilité

Quand l'analyse est produite par un outil, plus personne ne se sent pleinement auteur du chiffre. C'est le risque le plus difficile à traiter.

Sans protocole d'évaluation, il n'y a pas de projet

La démo est toujours convaincante. C'est le passage à l'échelle qui décide.

Protocole

- Extraction : précision / rappel par type de champ
- RAG : taux de réponses **sourcées et exactes**
- Résumé : taux d'affirmations non étayées
- Screening : précision@k sur un *peer group* de référence

- Constituer un **jeu de test annoté** par des analystes (200–500 items)
- Figer ce jeu, ne jamais l'utiliser pour régler les prompts
- Mesurer aussi le **temps humain** économisé, pas seulement l'exactitude
- Mesurer le **coût d'une erreur** non détectée

Un système à 95% d'exactitude sur des chiffres financiers n'est pas utilisable sans relecture : il faut savoir lesquels des 5% sont faux.



Atelier : concevoir votre chaîne de traitement

Consigne (par groupes)

Vous êtes missionnés sur l'acquisition d'une PME agro-alimentaire de 80 M€ de CA. Vous disposez de 6 semaines et d'une data room de 4000 documents.

- 1 Listez les **5 questions** dont la réponse conditionne le prix
- 2 Pour chacune : quelle **tâche** de TALN ? quel (x, y) ?
- 3 Quel niveau d'automatisation acceptez-vous ?
 - suggestion / pré-remplissage / décision
- 4 Où placez-vous la **relecture humaine** obligatoire ?
- 5 Quelles données **n'ont pas le droit** de sortir du périmètre ?
- 6 Comment mesurez-vous que le système fonctionne ?

Livrable : un schéma de chaîne + une grille d'évaluation.