

RISQUES & DISCUSSION ÉTHIQUE

SÉANCE 3/3 : CE QUE L'IA GÉNÉRATIVE ENGAGE

AgroParisTech — Dominante GIPE

Cas d'usage : évaluation de la valeur des entreprises

Vincent Guigue

vincent.guigue@agroparistech.fr

<https://vguigue.github.io>

LES RISQUES ASSOCIÉS À CES USAGES



Discrimination, exclusion and toxicity

Harms that arise from the language model producing discriminatory and exclusionary speech.



Information hazards

Harms that arise from the language model leaking or inferring true sensitive information.



Misinformation harms

Harms that arise from the language model producing false or misleading information.



Malicious uses

Harms that arise from actors using the language model to intentionally cause harm.

Human-computer
interaction harms

Harms that arise from users overly trusting the language model, or treating it as human-like.




Automation, access
and environmental harms

Harms that arise from environmental or downstream economic impacts of the language model.




Accès à l'information

- Accès à des informations dangereuses/interdites
 - +Données personnelles
 - Droit à l'oubli numérique
- Autorités informationnelles
 - Nature : inconsciemment, image = vérité
 - Source : presse, réseaux sociaux, ...
 - Volume : nombre de variantes, citations (pagerank)
- Génération de texte : harcèlement...
- Anthropomorphisation de l'algorithme
 - Distinguer humain et machine





Apprentissage automatique & biais



Oreilles pointues,
moustaches, texture de poils
=
Chat



Homme blanc, +40ans,
costume
=
Cadre supérieur

Biais dans les données $\Rightarrow$ biais dans les réponses

L'apprentissage automatique repose sur l'extraction de biais statistiques...

$\Rightarrow$ Lutter contre les biais = ajustement manuel de l'algorithme



Apprentissage automatique & biais



Stéréotypes tirés de *Pleated Jeans*

Google Traduction



✎ Texte

🖼 Images

📄 Documents

🌐 Sites Web

Détecter la langue

Anglais

Français



Français

Anglais

Arabe



The nurse and the doctor



L'infirmière et le médecin



- Choix du genre
- Couleur de peau
- Posture
- ...

Biais dans les données $\Rightarrow$ biais dans les réponses

L'apprentissage automatique repose sur l'extraction de biais statistiques...

$\Rightarrow$ Lutter contre les biais = ajustement manuel de l'algorithme



Correction des biais & ligne éditoriale

Correction des biais :

- Sélection de données spécifiques, rééquilibrage
- Censure de certaines informations
- Censure des résultats de l'algorithme

⇒ Travail éditorial...

Réalisé par qui ?

- Experts du domaine / cahier des charges
- Ingénieurs, lors de la conception de l'algorithme
- Groupe éthique, lors de la validation des résultats
- Équipe communication / réponses aux utilisateurs

⇒ Quelle légitimité ? Quelle transparence ? Quelle efficacité ?






L'apprentissage automatique n'est **jamais** neutre


- 1 Sélection des données
 - Sources, équilibre, filtrage
- 2 Transformation des données
 - Sélection + combinaison d'informations
- 3 Connaissances a priori
 - Équilibre, fonction de perte (loss), a priori, choix des opérateurs...
- 4 Filtrage des sorties
 - Post-traitement
 - Censure, redirection, ...

⇒ Des choix qui influencent les résultats de l'algorithme






Fuites de données



- Transmission de données sensibles
- Exploitation des données par OpenAI (ou d'autres)
- Fuite de données dans de futurs modèles




Des niveaux de risques vs sécurisation





Problèmes de Sécurité


- Extensions / Plug-ins $\Rightarrow$ Souvent des vulnérabilités de sécurité importantes pour les utilisateurs
 - Accès aux e-mails / transfert d'informations sensibles, etc.
- Problèmes de gestion pour les entreprises
 - Sécurisation de (très) gros fichiers
- Augmentation des opportunités pour les signatures de logiciels malveillants (malware)
 - $\approx$ reformulation logicielle
- Nouveaux problèmes !
 - Génération directe de logiciels malveillants (malware)






Défi dans l'enseignement

- Redéfinir des priorités pédagogiques, sujet par sujet, comme pour Wikipedia/calculatrice/...
 - Accepter la **perte/réduction de certaines compétences**
- Former les étudiants aux LLMs... et savoir parfois les interdire



- Détecter **les contenus générés par LLM**, connaître les outils





Détection des *textes générés par chatGPT*

Reformulation par chatGPT

Trier les documents par Date de dépôt 1 - 2 sur 2

☐		Plagiat Def 2 #4483eb 07/01/2023 19:18 par vous 122 mots 19,47 ko Plus d'infos	  0%	 Rapport	
☐		Plagiat Def 1 #f90ff3 07/01/2023 19:16 par vous 135 mots 16,78 ko Plus d'infos	  100%	 Rapport	

Définition de Wikipedia

L'externalité fait référence au fait qu'une activité économique d'un agent peut avoir un impact sur d'autres personnes sans qu'il y ait de compensation financière. Cela peut être bénéfique pour les autres, comme offrir une utilité gratuitement, ou nuisible, comme causer des dommages.

L'externalité caractérise le fait qu'un agent économique crée, par son activité, un effet externe en procurant à autrui, sans contrepartie monétaire, une utilité ou un avantage de façon gratuite, ou au contraire une nuisance, un dommage sans compensation (coût social, coût écosystémique, pertes de ressources pas, peu, difficilement, lentement ou coûteusement renouvelables...).


De la sorte, un agent économique se trouve en position d'influer consciemment ou inconsciemment sur la situation d'autres agents, sans que ceux-ci soient parties prenantes à la décision : ces derniers ne sont pas forcément informés et/ou n'ont pas été consultés et ne participent pas à la gestion de ses conséquences par le fait qu'ils ne reçoivent (si l'influence est négative), ni ne paient (si l'influence est positive) aucune compensation.

En résumé : « Tout coûte mais tout ne se paie pas »

Crédit: S.
Pajak



Détection des *textes générés par* chatGPT



- **Classifieur de texte** (comme pour n'importe quel auteur)
 - Détection des biais dans le choix des mots / la formulation
- Caractérisation de la **vraisemblance** du texte (OpenAI, GPTZero)
 - Hyper-fluidité des phrases, surabondance de connecteurs logiques
 - Modèle de langage = statistique $\Rightarrow$ mesure entre distributions (**perplexité**)
- δ -**vraisemblance** sur des textes perturbés (DetectGPT)

Détecteurs $\Rightarrow$ détection $< 100\%$

- + niveau de confiance dans la détection
- dépend de la longueur du texte et des modifications effectuées
- $\approx$ détecte des morceaux de Wikipédia (chatGPT = *perroquet stochastique*)
- ⚠ détecte la traduction comme la génération




Déclin / évolution cognitive

Notre cerveau va évoluer avec ces nouveaux outils...



Quelle est la portée de ces transformations? Quelles en seront les conséquences?

- Les sciences de l'éducation et la psychologie l'avait conjecturé...
les sciences cognitives l'ont mesuré





Risques/Questions juridiques



Biais cognitif	Effet sur l'utilisateur	IA génératives	IA & diag. médical
Biais d'automatisation	Acceptation passive des résultats (réduction de la vérification)	Élevé	Très élevé
Biais d'autorité	Surestimation de l'autorité (et de la fiabilité) de l'IA	Élevé	Très élevé
Surconfiance / mauvaise calibration de la confiance	Utilisation inappropriée de l'IA dans des situations où elle est peu fiable	Très élevé	Élevé
Biais de confirmation	Renforcement d'hypothèses erronées et réduction de l'exploration d'alternatives	Modéré	Élevé
Décharge cognitive	Diminution de l'analyse critique et de la métacognition	Élevé	Très élevé
Effet de cadrage. Illusion de profondeur explicative	Interprétation biaisée du niveau de certitude ou de risque (style de la réponse, présentation de chiffres)	Très élevé	Modéré
Biais d'anthropomorphisme	Attribution de capacités humaines (confiance++)	Très élevé	Modéré




Questions économiques

- Financement/Publicité $\Leftrightarrow$ **visites** des internautes
- Google Knowledge Graph (2012) $\Rightarrow$ moins de visites, donc moins de revenus
- chatGPT = encodage de l'information du web... $\Rightarrow$ encore moins de visites ?

$\Rightarrow$ Quel **modèle économique** / **sources d'information** avec chatGPT ?

Google's Knowledge Graph Boxes: killing Wikipedia?

by Gregory Kohs



$\Rightarrow$ Qui **bénéficie du retour d'information** ? [StackOverflow]




Risques liés à la généralisation de l'IA

L'IA partout =

perte de sens ?

- Dans le domaine éducatif
- Transposition aux RH
- Aux systèmes de financement par projet



DISCUSSION ÉTHIQUE



Quelle approche de la question éthique ?

Médecine

- 1 **Autonomie** : le patient doit pouvoir prendre des décisions éclairées.
- 2 **Bienfaisance** : obligation d'agir pour le bien, dans l'intérêt du patient.
- 3 **Non-malfaisance** : éviter de causer du tort, évaluer les risques et les bénéfices.
- 4 **Égalité** : équité dans la répartition des ressources et des soins de santé.
- 5 **Confidentialité** : garantir la confidentialité des informations du patient.
- 6 **Vérité et transparence** : fournir une information honnête, complète et compréhensible.
- 7 **Consentement éclairé** : obtenir le consentement libre et éclairé des patients.
- 8 **Respect de la dignité humaine** : traiter chaque patient avec respect et dignité.

Intelligence artificielle

- 1 **Autonomie** : les humains gardent le contrôle du processus
- 2 **Bienfaisance** : dans l'intérêt de qui ?
Utilisateur + GAFAM...
- 3 **Non-malfaisance** : humains + environnement
/ durabilité / usages malveillants
- 4 **Égalité** : accès à l'IA et égalité des chances
- 5 **Confidentialité** : qu'en est-il du modèle économique de Google/Facebook ?
- 6 **Vérité et transparence** : la tragédie de l'IA moderne
- 7 **Consentement éclairé** : des cookies aux algorithmes, savoir quand on interagit avec une IA
- 8 **Respect de la dignité humaine** : comportements de harcèlement / distinction humain-machine



Quelle approche de la question éthique ?

Médecine

- 1 **Autonomie** : le patient doit pouvoir prendre des décisions éclairées.
- 2 **Bienfaisance** : obligation d'agir pour le bien, dans l'intérêt du patient.
- 3 **Non-malfaisance** : éviter de causer du tort, évaluer les risques et les bénéfices.
- 4 **Égalité** : équité dans la répartition des ressources et des soins de santé.
- 5 **Confidentialité** : garantir la confidentialité des informations du patient.
- 6 **Vérité et transparence** : fournir une information honnête, complète et compréhensible.
- 7 **Consentement éclairé** : obtenir le consentement libre et éclairé des patients.
- 8 **Respect de la dignité humaine** : traiter chaque patient avec respect et dignité.

Intelligence artificielle

- 1 **Autonomie** : les humains gardent le contrôle du processus
- 2 **Bienfaisance** : dans l'intérêt de qui ?
Utilisateur + GAFAM...
- 3 **Non-malfaisance** : humains + environnement
/ durabilité / usages malveillants
- 4 **Égalité** : accès à l'IA et égalité des chances
- 5 **Confidentialité** : qu'en est-il du modèle économique de Google/Facebook ?
- 6 **Vérité et transparence** : la tragédie de l'IA moderne
- 7 **Consentement éclairé** : des cookies aux algorithmes, savoir quand on interagit avec une IA
- 8 **Respect de la dignité humaine** : comportements de harcèlement / distinction humain-machine



Discussion : jusqu'où puis-je aller ?

Puis-je utiliser un assistant conversationnel pour :

- 1 chercher des idées ? me faire expliquer une notion (le calcul du BFR, l'IFRS 16) ?
- 2 traduire un paragraphe d'un contrat ?
- 3 rédiger un paragraphe à partir de notes en *bullet points* ?
- 4 chercher de la documentation sectorielle, des comparables ?
- 5 résumer un rapport annuel que je veux lire ?
- 6 résumer un document de la data room que je dois auditer ?
- 7 rédiger la section "risques" de la note d'investissement ?
- 8 poser des questions sur un document confidentiel du client ?
- 9 convertir un modèle Excel en code Python ?
- 10 écrire 10 lignes de code pour tester une bibliothèque ?
- 11 construire le modèle de valorisation complet ?

Où placez-vous la limite ? Et surtout : **pourquoi là ?**



Discussion : et si ça tourne mal ?

Quelle est ma réaction si :

- 1 un associé trouve une erreur dans un paragraphe rédigé par un chatbot ;
- 2 un associé **ne trouve pas** une erreur existante dans ce paragraphe ;
- 3 le client trouve une erreur dans mes résultats... produits par du code généré ;
- 4 on découvre que ma synthèse de due diligence n'est pas fiable ;
- 5 je découvre que des passages du mémorandum reçu de la partie adverse sont générés par IA ;
- 6 je découvre que le document confidentiel que j'ai soumis à une API a servi à entraîner un modèle ;
- 7 la valorisation proposée par la machine a ancré une négociation à 15% au-dessus du prix juste.

Qui est responsable ? L'analyste, le cabinet, l'éditeur du modèle, personne ?



Trois questions pour structurer le débat

1. La question de la **délégation**

Qu'est-ce que j'accepte de ne plus faire moi-même ?

Et que suis-je encore capable de vérifier une fois que je ne le fais plus ?

2. La question de la **transparence**

Dois-je déclarer l'usage de l'IA ? À qui ? Au client, à l'associé, au régulateur ?

Que change une déclaration ? Que change son absence ?



3. La question de l'**asymétrie**

Ce que j'accepte pour moi, l'accepterais-je de la part de ma contrepartie ?


De mon auditeur ? De mon employeur à mon sujet ?

CONCLUSION

Les représentations de l'Intelligence Artificielle




Schrodinger's cat





Mary's room




3 laws of robotics (Asimov)



Maxwell's demon



These's boat





Défis à venir

■ Qu'en est-il des hallucinations ?

- Faut-il chercher à les réduire ou apprendre à vivre avec ?
- Les LLM vont-ils s'améliorer ? Dans quelles directions ?
- Les LLM nous font-ils *perdre* notre lien à la vérité ? À la vérification ?

■ Avons-nous besoin de petits ou de grands modèles de langue ?

- Combien cela coûte-t-il ? Est-ce durable ?
- Avec ou sans ajustement fin (fine-tuning) ?
- Que signifie la frugalité dans le monde des LLM ?

■ Quand les autres les utilisent... Quel impact cela a-t-il sur moi ?

- Productivité (chercheurs, codeurs, relecteurs, ...)
- Éducation : gestion / formation d'étudiants *technophiles*

■ Protection des données... les miennes et celles des autres

- Est-il raisonnable d'entraîner des LLM sur GitHub, Wikipédia, des articles scientifiques, des sites d'actualités, etc. ?
- Quelle importance accorder à la vie privée ? Quels sont les risques liés à l'usage d'un LLM ?



Défis à venir

■ Qu'en est-il des hallucinations ?

- Faut-il chercher à les réduire ou apprendre à vivre avec ?
- Les LLM vont-ils s'améliorer ? Dans quelles directions ?
- Les LLM nous font-ils *perdre* notre lien à la vérité ? À la vérification ?

■ Avons-nous besoin de petits ou de grands modèles de langue ?

- Comparer les capacités des petits et des grands modèles
- A-t-on besoin de grands modèles ?
- Comparer les capacités des petits et des grands modèles

Le smartphone a fait de moi un *humain augmenté*...

Le LLM fera-t-il de moi un *chercheur augmenté* ?

⇒ Jetez donc un œil à **NotebookLM**

■ Quand les autres les utilisent... Quel impact cela a-t-il sur moi ?

- Productivité (chercheurs, codeurs, relecteurs, ...)
- Éducation : gestion / formation d'étudiants *technophiles*

■ Protection des données... les miennes et celles des autres

- Est-il raisonnable d'entraîner des LLM sur GitHub, Wikipédia, des articles scientifiques, des sites d'actualités, etc. ?
- Quelle importance accorder à la vie privée ? Quels sont les risques liés à l'usage d'un LLM ?




Niveaux d'accès à l'intelligence artificielle

- 1 Utilisateur via une interface : *chatGPT*
 - Une formation reste nécessaire (2–4 h)
- 2 Utilisation de bibliothèques Python
 - Bases sur les protocoles
 - Chaînes de traitement standards
 - Formation : 1 semaine à 3 mois (ML/DL)
- 3 Développeur d'outils
 - Adapter les outils à un cas spécifique
 - Intégrer des contraintes métier
 - Construire des systèmes hybrides (mécanistes / symboliques)
 - Combiner texte et images
 - Formation : ≥ 1 an




Souveraineté numérique : toute la chaîne





Une multitude de métiers





Facteurs d'acceptabilité de l'IA générative

1 Utilitarisme :


- Performance (facteur d'acceptation de ChatGPT)
- Fiabilité / auto-évaluation

2 Non-dangérosité :

- Biais / correction
- Transparence (ligne éditoriale, confusion humain/machine)
- Mise en œuvre fiable
- Souveraineté (?)
- Régulation (AI Act)
 - Éviter les applications dangereuses

3 Savoir-faire :

- Formation (utilisation / développement)



Pourquoi tant de controverses ?

- Nouvel outil [Décembre 2022]
- + Vitesse d'adoption sans précédent [1 million d'utilisateurs en 5 jours]
- Forces et faiblesses... mal comprises par les utilisateurs
 - Gains de productivité importants
 - Usages surprenants / parfois absurdes
 - Biais / usages dangereux / risques
- Retours mal interprétés
 - Anthropomorphisation de l'algorithme et de ses erreurs
- Coût prohibitif : quel modèle économique, écologique et sociétal ?

